

Pendekatan Ensemble Random Forest dan CatBoost dalam Memprediksi Rentang Gaji Calon Karyawan Berdasarkan Curriculum Vitae

Musliadist
Fakultas Matematika dan Ilmu
Pengetahuan Alam
Departemen Statistika
Banda Aceh, Indonesia
musliad6@mhs.usk.ac.id

Muhammad Zulkarnainind
Fakultas Matematika dan Ilmu
Pengetahuan Alam
Departemen Statistika
Banda Aceh, Indonesia
zul22@mhs.usk.ac.id

Nabilard
Fakultas Matematika dan Ilmu
Pengetahuan Alam
Departemen Statistika
Banda Aceh, Indonesia
nabilaltmpt22@gmail.com

Abstract—Penentuan rentang gaji yang kompetitif merupakan tantangan krusial dalam proses rekrutmen modern, di mana pendekatan tradisional seringkali bersifat subjektif dan tidak konsisten. Penelitian ini mengusulkan sebuah pipeline machine learning end-to-end untuk memprediksi rentang gaji secara akurat berdasarkan data multi-dimensi yang diekstrak dari curriculum vitae (CV). Metodologi yang diterapkan mencakup rekayasa fitur komprehensif untuk mentransformasi data heterogen termasuk data numerik, kategorikal, dan tekstual menjadi representasi yang informatif. Fitur-fitur kunci diekstraksi dari pengalaman kerja, latar belakang pendidikan, dan keterampilan teknis menggunakan teknik seperti TF-IDF. Model prediksi dibangun menggunakan metode ensemble yang menggabungkan kekuatan Random Forest dan CatBoost, yang selanjutnya dioptimalkan melalui seleksi fitur, pembobotan, dan transformasi log pada variabel target. Hasil evaluasi menggunakan 5-Fold Cross-Validation menunjukkan bahwa model final berhasil mencapai Mean Absolute Error (MAE) sebesar 1.248.365. Analisis feature importance mengonfirmasi bahwa tingkat senioritas, total pengalaman kerja, domisili, dan penguasaan teknologi spesifik seperti Docker dan PostgreSQL menjadi faktor pendorong utama dalam prediksi. Penelitian ini menghasilkan sebuah kerangka kerja yang valid dan dapat diimplementasikan untuk menyediakan alat bantu keputusan berbasis data bagi praktisi sumber daya manusia, guna meningkatkan objektivitas dan efisiensi dalam penawaran gaji.

Keywords— *Prediksi Gaji, Machine Learning, Future Engineering, Metode Ensemble, Random Forest, CatBoost, Sumber Daya Manusia.*

I. PENDAHULUAN

A. Latar Belakang

Selama beberapa tahun terakhir, pasar tenaga kerja global mengalami perubahan mendasar akibat digitalisasi, disrupti teknologi, serta pergeseran pola ekonomi [1]. Kondisi ini menuntut perusahaan di berbagai bidang untuk merancang strategi rekrutmen yang lebih responsif, efisien, dan berbasis analisis data. Salah satu aspek terpenting dalam proses perekrutan adalah penentuan rentang gaji, khususnya kisaran gaji yang ditawarkan kepada calon karyawan [2]. Sayangnya, penentuan gaji di banyak organisasi masih didasarkan pada intuisi perekrut, survei pasar yang terbatas, atau data historis yang tidak selalu representatif. Kondisi ini sering kali memunculkan bias, kesenjangan informasi, serta ketidaksesuaian antara ekspektasi kandidat dengan penawaran perusahaan.

Seiring dengan meningkatnya ketersediaan informasi kandidat melalui data yang tercantum pada *curriculum vitae* (CV), peluang untuk mengembangkan pendekatan berbasis data semakin terbuka. Informasi seperti jabatan saat ini, posisi yang ditargetkan, total pengalaman kerja, tingkat senioritas, latar belakang pendidikan, sertifikasi, keterampilan teknis, hingga domisili mencerminkan variabel yang relevan untuk memperkirakan rentang gaji. Tantangannya, data tersebut bersifat heterogen, terdiri dari kombinasi numerik, kategorikal, dan teks bebas yang tidak selalu terstruktur. Kompleksitas ini membuat pendekatan prediksi tradisional kurang optimal.

Kajian akademik sebelumnya telah mengeksplorasi pemanfaatan *machine learning* dalam proses rekrutmen, misalnya untuk *resume screening* berbasis *Natural Language Processing* (NLP), prediksi tingkat retensi karyawan, hingga sistem rekomendasi kandidat [3]. Beberapa penelitian juga membahas estimasi gaji berbasis data survei pasar tenaga kerja atau platform perekrutan daring [4]. Namun, sebagian besar pendekatan tersebut masih berfokus pada dataset yang terbatas (misalnya hanya data numerik atau hanya berdasarkan jabatan), sehingga belum sepenuhnya mengintegrasikan keragaman informasi yang tercantum dalam CV kandidat. Dengan demikian, terdapat celah penelitian yang penting: bagaimana membangun model prediksi gaji yang mampu memanfaatkan data multi-dimensi dari CV secara terpadu untuk menghasilkan estimasi yang lebih akurat dan adil.

Makalah ini menerapkan metode ensemble melalui kombinasi Random Forest dan CatBoost, yang diharapkan mampu memberikan estimasi kisaran gaji secara akurat berdasarkan data yang dikumpulkan dari CV.

B. Rumusan Masalah

Berdasarkan latar belakang mengenai kesulitan dalam penentuan gaji yang kompetitif, maka rumusan masalah dalam penelitian ini adalah:

- 1) Apa saja tantangan teknis dalam pengembangan sistem prediksi rentang gaji yang akurat?
- 2) Bagaimana merancang sebuah *pipeline machine learning end-to-end* yang efektif untuk memprediksi rentang gaji kandidat berdasarkan data multi-dimensi?
- 3) Bagaimana hasil prediksi dari model ini dapat diimplementasikan untuk membantu perusahaan mengoptimalkan strategi rekrutmen dan proses penawaran gaji?

C. Tujuan dan Manfaat

Adapun tujuan makalah ini adalah merancang, membangun, dan mengevaluasi *pipeline machine learning end-to-end* untuk prediksi gaji, dengan mengidentifikasi tantangan teknis pada data rekrutmen multi-dimensi. Harapannya makalah ini dapat memberi manfaat untuk setiap *stakeholder* yaitu sebagai berikut:

1) Bagi Perusahaan (Tim HR & Perekrutan)

Memberikan dasar pengambilan keputusan yang objektif dan berbasis data untuk menetapkan penawaran gaji yang kompetitif, sehingga meningkatkan efisiensi dan keberhasilan proses rekrutmen.

2) Bagi Calon Karyawan

Meningkatkan transparansi dan keadilan dalam proses penawaran gaji, memastikan mereka menerima kompensasi yang sesuai dengan kualifikasi, pengalaman, dan standar pasar yang berlaku.

3) Bagi Peneliti

Menyajikan studi kasus dan kerangka kerja praktis tentang penerapan *machine learning end-to-end* untuk prediksi data multi-dimensi di bidang sumber daya manusia, yang dapat menjadi acuan bagi penelitian selanjutnya.

II. PEMBAHASAN


A. Landasan Teori

1) Feature engineering

Feature engineering merupakan tahap dalam pembelajaran mesin yang mencakup persiapan, transformasi, pembuatan, dan penyaringan fitur untuk meningkatkan performa model. Proses ini bertujuan agar data menjadi lebih informatif sehingga model dapat belajar dengan lebih efektif dan memberikan prediksi yang lebih akurat [5].

2) K-Fold Cross Validation


K-fold cross validation adalah teknik evaluasi statistik yang digunakan untuk mengukur kemampuan generalisasi dan akurasi model. Data dibagi menjadi K bagian, kemudian model dilatih sebanyak K kali, dengan setiap iterasi menggunakan K-1 bagian sebagai data latih dan satu bagian sisanya sebagai data uji [6].



Gambar 1. Ilustrasi K-Fold Cross Validation

3) Random Forest


Random Forest adalah algoritma pembelajaran mesin yang termasuk metode ensemble, menggunakan sejumlah pohon keputusan untuk meningkatkan akurasi prediksi. Setiap pohon dibentuk dengan memilih subset data dan fitur secara acak, kemudian hasil prediksi dari semua pohon digabung untuk menghasilkan keputusan akhir [7].



Gambar 2. Ilustrasi Random Forest

4) Categorical Boosting

CatBoost adalah algoritma gradient boosting yang khusus dirancang untuk menangani fitur kategorikal tanpa memerlukan pra-pemrosesan khusus. Algoritma ini memanfaatkan teknik seperti penghitungan statistik target berurutan dan boosting berurutan untuk meningkatkan performa prediksi [8].



Gambar 3. Ilustrasi Catboost

5) Metode Ensemble

Metode ensemble menggabungkan beberapa model dasar untuk meningkatkan kualitas prediksi. Teknik ini mencakup strategi seperti bagging, boosting, dan stacking, yang bertujuan untuk mengurangi bias dan variansi sehingga prediksi menjadi lebih stabil dan akurat [9].

6) Mean Absolute Error

Mean Absolute Error (MAE) adalah metrik kesalahan yang menghitung rata-rata selisih absolut antara nilai prediksi dan nilai nyata. MAE menilai semua kesalahan dengan bobot yang sama, tanpa memperhitungkan arah kesalahan tersebut [10].

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

B. Metode Penelitian

1) Dataset

Dataset penelitian diperoleh dari IFEST UNPAD: Data Analysis Competition, yang terdiri atas 1,618 data latih dan 291 data uji yang berisi rentang gaji kandidat berdasarkan Informasi yang terdapat pada CV. Data terdiri dari 14 fitur dan 2 target (Estimate Bottom dan Estimate Up).


2) Alur Kerja Penelitian

Penelitian ini mengadopsi alur kerja *machine learning* yang sistematis dan iteratif. Dimulai dari

analisis data eksploratif untuk memahami karakteristik, pola, serta potensi masalah dalam data, kemudian dilanjutkan dengan *preprocessing* untuk memastikan kualitas data yang akan digunakan pada tahap pemodelan. Langkah ini penting agar model dapat mempelajari hubungan antar variabel secara lebih akurat tanpa terganggu oleh noise, ketidakkonsistenan, atau ketidakseimbangan dalam data.

Selanjutnya *preprocessing* data dalam makalah ini dilakukan secara komprehensif untuk memastikan model dapat belajar dari informasi yang relevan dan bersih. Pada tahap *feature engineering*, dilakukan pembersihan dan standarisasi data seperti menyamakan penulisan domisili, menghitung jumlah sertifikasi, serta membersihkan kolom *Tech Stack* agar konsisten. Selanjutnya, informasi tambahan diekstraksi melalui penggabungan jabatan *Current Position* dan *Targeted Position* untuk menghasilkan fitur biner berbasis kata kunci (misalnya *is_manager*, *is_senior*, atau *is_backend*), serta mengolah data pendidikan menjadi fitur gabungan seperti *has_s1*, *is_it_major*, dan *is_bootcamp_grad*. Dari sisi waktu, dihitung pula lama sejak kelulusan terakhir untuk menambah konteks pengalaman kandidat. Pada tahap penanganan data, nilai hilang diimputasi menggunakan median, sementara variabel kategorikal diencoding menjadi numerik agar dapat diproses model. Untuk data teks, digunakan TF-IDF dengan 200 fitur teratas agar representasi keahlian lebih terstruktur.

Setelah menghasilkan banyak fitur, seleksi fitur berbasis *feature importance* dari model *CatBoost* sementara dilakukan, dan hanya 100 fitur teratas dipilih agar model lebih efisien serta terhindar dari *noise*. Terakhir, target variabel berupa estimasi gaji (*Estimate Bottom* dan *Estimate Up*) ditransformasi menggunakan logaritma alami (np.log1p) untuk mengurangi *skewness* distribusi dan membantu model dalam mempelajari pola yang lebih stabil.




Gambar 4. Alur Kerja Penelitian

C. Hasil dan Pembahasan

Bagian ini menyajikan analisis komprehensif dari hasil penelitian, dimulai dari analisis data eksploratif untuk memahami karakteristik dataset, diikuti oleh evaluasi kuantitatif dari *pipeline* prediksi gaji yang dikembangkan secara iteratif.

1) Analisis Deskriptif

Tahap awal analisis berfokus pada pemahaman distribusi data. Gambar 5 menyajikan visualisasi boxplot untuk variabel *estimated bottom salary* dan *estimated up salary* berdasarkan wilayah.



Gambar 5. Analisis Deskriptif

Gambar di atas menunjukkan visualisasi boxplot untuk variabel *estimated bottom salary* dan *estimated up salary* berdasarkan wilayah. Setiap daerah memiliki rentang estimasi gaji yang terlihat dari panjang box (IQR) dan whisker sebagai batas bawah dan atas, dengan median menggambarkan nilai tengah gaji. Beberapa titik *outlier* menunjukkan estimasi gaji yang jauh lebih rendah atau lebih tinggi dari pola umum. Terlihat adanya perbedaan signifikan antar daerah, di mana sebagian memiliki distribusi gaji lebih tinggi dan stabil, sedangkan lainnya menunjukkan variasi yang lebih lebar dan heterogen.

Setelah memahami karakteristik data awal, penelitian dilanjutkan dengan membangun dan mengevaluasi model prediksi secara sistematis. Analisis difokuskan pada dampak setiap komponen metodologis terhadap akurasi model, yang diukur menggunakan metrik MAE. Tabel I merangkum evolusi kinerja model yang akan dibahas lebih lanjut.

TABLE I. EVOLUSI PERFORMA MODEL MELALUI EKSPERIMEN PROSEDURAL

No.	Tahap Eksperimen	Deskripsi Metode	MAE
-----	------------------	------------------	-----

1	Model Dasar	Random Forest dilatih pada fitur fundamental.	1,539,465.08
2	Fitur Tekstual Awal	Model #1 ditambah jumlah_sertifikasi dan TF-IDF.	1,357,419.26
3	Fitur Kontekstual & Waktu	Model #2 ditambah fitur dari Education, Position, & Lama_Sejak_Lulus.	1,336,809.38
4	Ensemble Sederhana	Menggabungkan Random Forest (tuned) & CatBoost (default) - 50/50.	1,281,458.88
5	Ensemble + Seleksi Fitur	Model #4 dilatih hanya pada Top 100 fitur.	1,263,223.88
6	Ensemble Berbobot	Model #5 dengan bobot diubah menjadi 65% Random Forest & 35% CatBoost.	1,260,187.57
7	Ensemble Berbobot + Transformasi Log	Model #6 dengan penerapan Log Transform pada variabel target.	1,260,187.57

2) Rekayasa Fitur dalam Mengekstraksi Sinyal Prediktif

Analisis hasil pada Tabel I menunjukkan bahwa rekayasa fitur merupakan fase yang memberikan peningkatan performa paling signifikan dalam keseluruhan *pipeline*. Lompatan kinerja terbesar, dengan penurunan MAE sebesar 11.8%, terjadi pada Tahap 2 saat fitur tekstual Tech Stack diolah menggunakan TF-IDF (*Term Frequency-Inverse Document Frequency*). Berbeda dengan pendekatan biner sederhana (ada/tidaknya suatu *skill*), TF-IDF mampu memberikan bobot pada setiap keterampilan teknis, merefleksikan kepentingannya secara relatif di seluruh dataset. Keterampilan yang langka namun sering muncul pada kandidat dengan gaji tinggi (misalnya, 'kubernetes' atau 'GCP') akan mendapatkan skor tinggi, memberikan sinyal yang jauh lebih kuat kepada model dibandingkan keterampilan umum (misalnya, 'HTML' atau 'CSS'). Hal ini secara efektif mentransformasi data teks yang tidak terstruktur menjadi fitur numerik yang kaya akan informasi domain.

Selanjutnya, pada Tahap 3, penambahan fitur kontekstual yang diekstraksi dari riwayat pendidikan dan posisi (misalnya, *is_it_major*, *is_lead*, *has_s1*) memberikan peningkatan tambahan. Meskipun peningkatannya lebih kecil (1.5%), tahap ini krusial karena berhasil mengkuantifikasi informasi naratif. Fitur-fitur biner ini berfungsi sebagai proksi untuk kualifikasi dan tingkat senioritas, yang sebelumnya tersembunyi dalam teks bebas. Dengan demikian, model tidak lagi perlu "mempelajari" hubungan ini dari awal, melainkan diberikan petunjuk eksplisit, yang membuatnya lebih efisien dalam menemukan pola yang relevan.

3) Efektivitas Metode Ensemble dan Seleksi Fitur untuk Generalisasi Model

Setelah fondasi fitur yang kuat terbentuk, fokus beralih ke optimasi arsitektur model untuk meningkatkan kemampuan generalisasi. Pada Tahap 4, penerapan metode *ensemble* memberikan penurunan MAE yang substansial (4.1%). Peningkatan ini dapat dijelaskan oleh sifat komplementer dari kedua model yang digunakan:

- Random Forest, sebagai algoritma berbasis *bagging*, membangun banyak *decision tree* secara independen pada *subset* data yang berbeda. Hal ini membuatnya sangat efektif dalam mengurangi varians dan robust terhadap *overfitting*.
- CatBoost, sebagai algoritma berbasis *gradient boosting*, membangun *tree* secara sekuensial, di mana setiap *tree* baru berusaha memperbaiki kesalahan dari *tree* sebelumnya. Hal ini membuatnya sangat kuat dalam mengurangi bias.

Dengan menggabungkan keduanya, *pipeline* secara simultan mengatasi dua sumber utama kesalahan prediksi (*bias* dan *variance*), menghasilkan model yang lebih seimbang dan akurat.


Selanjutnya, pada Tahap 5, penerapan seleksi fitur terbukti memberikan manfaat. Meskipun tampak kontra-intuitif untuk membuang sebagian fitur, langkah ini sangat penting. Ketika jumlah fitur sangat banyak, ada risiko model akan mempelajari pola dari fitur-fitur yang tidak relevan atau bahkan dari noise acak dalam data. Dengan melatih model hanya pada 100 fitur paling prediktif, kita secara efektif menghilangkan gangguan dan korelasi palsu. Hal ini memaksa model untuk fokus pada sinyal informasi yang paling kuat, sehingga kemampuannya untuk membuat prediksi yang akurat pada data baru (generalisasi) menjadi lebih baik.

Penyempurnaan akhir melalui pembobotan ensemble (Tahap 6) dan transformasi log (Tahap 7) merupakan langkah fine-tuning yang presisi. Bobot 65/35 yang ditemukan melalui eksperimen menunjukkan bahwa dalam kasus ini, model Random Forest memberikan kontribusi yang sedikit lebih dominan. Sementara itu, transformasi log secara efektif menangani distribusi gaji yang miring ke kanan (*right-skewed*), mencegah model menjadi terlalu terdistorsi oleh beberapa titik data dengan gaji sangat tinggi dan memastikan prediksinya tetap stabil di seluruh rentang gaji. Model final dengan MAE sebesar 1.248.365 adalah hasil dari serangkaian optimasi yang terukur dan dapat dijustifikasi secara teknis pada setiap tahapannya.

4) Feature Importance

Tahapan ini dimaksudkan untuk memberikan pemahaman mendalam mengenai faktor-faktor pendorong prediksi model, dilakukan analisis feature importance guna mengukur kontribusi relatif dari setiap variabel. Proses ini bertujuan untuk meningkatkan interpretabilitas model dengan mengidentifikasi fitur mana yang paling dipertimbangkan dalam membuat keputusan. Visualisasi pada Gambar 6 menunjukkan hasil analisis ini, yang memberikan wawasan strategis dan selaras dengan logika bisnis di dunia rekrutmen. Terlihat jelas bahwa Candidate Level (tingkat senioritas) dan Total Working Experience (total pengalaman kerja) secara absolut mendominasi sebagai prediktor utama, yang

mengonfirmasi bahwa senioritas dan durasi pengalaman adalah fondasi kompensasi dalam industri teknologi. Selanjutnya, Domisili_Clean menempati urutan ketiga, membuktikan secara kuantitatif bahwa lokasi geografis memiliki pengaruh signifikan terhadap estimasi gaji. Selain faktor umum tersebut, model juga berhasil mengidentifikasi nilai pasar dari penguasaan teknologi spesifik yang sedang diminati, seperti docker, postgresql, dan redis, yang muncul dalam sepuluh besar. Kehadiran fitur-fitur ini, bersama dengan jumlah_sertifikasi dan spesialisasi peran seperti is_mobile, menunjukkan bahwa model tidak hanya belajar dari informasi umum, tetapi juga mampu menangkap sinyal-sinyal kualifikasi yang lebih halus. Analisis ini secara efektif memvalidasi bahwa model belajar dari variabel yang relevan dan memberikan panduan bagi tim rekrutmen mengenai faktor-faktor kunci dalam evaluasi kompensasi kandidat.



Gambar 6. Feature importance

III. PENUTUP

A. Kesimpulan

Penelitian ini berhasil merancang, membangun, dan mengevaluasi sebuah pipeline machine learning end-to-end yang efektif untuk menjawab tantangan dalam prediksi rentang gaji berbasis data CV multi-dimensi. Berdasarkan rumusan masalah dan hasil yang diperoleh, dapat ditarik beberapa kesimpulan utama:

- 1) Tantangan teknis dalam prediksi gaji, seperti data yang heterogen dan tidak terstruktur, berhasil diatasi melalui rekayasa fitur yang komprehensif. Teknik seperti TF-IDF untuk data tekstual dan ekstraksi fitur kontekstual terbukti menjadi fase paling krusial yang secara signifikan meningkatkan performa model.
- 2) Rancangan pipeline yang mengintegrasikan rekayasa fitur, seleksi fitur, dan metode ensemble terbukti sangat efektif. Kombinasi antara Random Forest dan CatBoost, yang disempurnakan melalui pembobotan dan transformasi log, mampu menghasilkan model yang akurat dan robust, dengan mencapai skor MAE akhir sebesar 1.248.365.
- 3) Implementasi hasil prediksi dari model ini dapat memberikan manfaat strategis bagi perusahaan.

Analisis feature importance mengonfirmasi bahwa faktor-faktor seperti tingkat senioritas, total pengalaman kerja, domisili, dan penguasaan teknologi spesifik adalah pendorong utama kompensasi. Dengan demikian, model ini dapat berfungsi sebagai alat bantu keputusan yang objektif untuk menetapkan penawaran gaji yang kompetitif, adil, dan berbasis data, sehingga mengoptimalkan strategi rekrutmen secara keseluruhan.

Penelitian ini menyajikan studi kasus dan kerangka kerja praktis yang dapat menjadi acuan bagi penelitian selanjutnya di bidang analisis sumber daya manusia.

REFERENCES

- [1] A. G. Ross, P. G. McGregor, and J. K. Swales, "Labour market dynamics in the era of technological advancements: The system-wide impacts of labour augmenting technological change," *Technol. Soc.*, vol. 77, no. March, p. 102539, 2024, doi: 10.1016/j.techsoc.2024.102539.
- [2] M. Ranta and M. Ylinen, "Employee benefits and company performance: Evidence from a high-dimensional machine learning model," *Manag. Account. Res.*, vol. 64, no. March 2022, p. 100876, 2024, doi: 10.1016/j.mar.2023.100876.
- [3] A. R. Alsheyab, M. Alkhasawneh, and N. Shahin, "Job Market Cheat Codes: Prototyping Salary Prediction and Job Grouping with Synthetic Job Listings," 2025, [Online]. Available: <http://arxiv.org/abs/2506.15879>
- [4] R. J. Snelgar, "The effects of different approaches to salary survey data analysis on pay curve midpoint values," *South African J. Econ. Manag. Sci.*, vol. 6, no. 4, pp. 905–916, 2003, doi: 10.4102/sajems.v6i4.1528.
- [5] C. Wang *et al.*, "Application of artificial intelligence for feature engineering in education sector and learning science," *Alexandria Eng. J.*, vol. 110, no. October, pp. 108–115, 2025, doi: 10.1016/j.aej.2024.09.100.
- [6] O. Chamorro-Atalaya *et al.*, "K-Fold Cross-Validation through Identification of the Opinion Classification Algorithm for the Satisfaction of University Students," *Int. J. online Biomed. Eng.*, vol. 19, no. 11, pp. 140–158, 2023, doi: 10.3991/ijoe.v19i11.39887.
- [7] Y. F. Zamzam, T. H. Saragih, R. Herteno, Muliadi, D. T. Nugrahadi, and P. H. Huynh, "Comparison of CatBoost and Random Forest Methods for Lung Cancer Classification using Hyperparameter Tuning Bayesian Optimization-based," *J. Electron. Electromed. Eng. Med. Informatics*, vol. 6, no. 2, pp. 125–136, 2024, doi: 10.35882/jeemi.v6i2.382.
- [8] A. A. Ibrahim, R. L. Ridwan, M. M. Muhammed, R. O. Abdulaziz, and G. A. Saheed, "Comparison of the CatBoost Classifier with other Machine Learning Methods," *Int. J. Adv. Comput. Sci. Appl.*, vol. 11, no. 11, pp. 738–748, 2020, doi: 10.14569/IJACSA.2020.0111190.
- [9] I. D. Mienye and Y. Sun, "A Survey of Ensemble Learning.," *IEEE Access*, vol. PP, p. 1, 2022, doi: 10.1109/ACCESS.2022.3207287.
- [10] S. M. R. Id and C. J. Willmott, "Decomposition of the mean absolute error (MAE) into systematic and unsystematic components," pp. 1–8, 2023, doi: 10.1371/journal.pone.0279774.

IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove template text from your paper may result in your paper not being published.

We suggest that you use a text box to insert a graphic (which is ideally a 300 dpi TIFF or EPS file, with all fonts embedded) because, in an MSW document, this method is somewhat more stable than directly inserting a picture.

To have non-visible rules on your frame, use the MSWord “Format” pull-down menu, select Text Box > Colors and Lines to choose No Fill and No Line.