

MAKALAH
DATA MINING INTELECTA 2025

**Analisis Kinerja Model Ensemble Machine Learning Dalam Prediksi Suhu Global
Berbasis Data Agrikultur Dan Geo-Temporal**



INTELECTA CUP

Oleh:

Glenn Hakim 2208107010072
Irfan Rizadi 2208107010062
Musliadi 2208108010061

BEYOND
UNIVERSITAS SYIAH KUALA

ABSTRAK

Perubahan iklim telah menjadi tantangan global yang mengancam ketahanan pangan melalui dampaknya terhadap sektor agrikultur. Penelitian ini bertujuan membangun dan mengevaluasi model machine learning yang andal untuk memprediksi suhu rata-rata tahunan, dengan memanfaatkan dataset komprehensif dari "Intelecta Cup Data Mining Competition" yang mencakup variabel agrikultur, lingkungan, dan geo-temporal. Metode yang digunakan adalah perbandingan tiga model ensemble terkemuka: Random Forest, XGBoost, dan LightGBM. Model-model ini dilatih dan dioptimalkan menggunakan hyperparameter tuning dan cross-validation, serta dievaluasi kinerjanya menggunakan metrik MAE, RMSE, dan MAPE. Hasil penelitian menunjukkan bahwa proses optimasi secara drastis meningkatkan kinerja model, menurunkan nilai MAE dari kisaran 8.9-9.4 menjadi di bawah 1.0. Model LightGBM teroptimasi menunjukkan performa terbaik dengan nilai MAE 0.79, RMSE 0.94, dan MAPE 329.00. Analisis feature importance mengidentifikasi bahwa Hasil Panen, Emisi CO₂, dan Indeks Kesehatan Tanah adalah tiga faktor paling berpengaruh terhadap prediksi suhu. Penelitian ini menyimpulkan bahwa LightGBM adalah model yang paling efektif untuk dataset non-linear ini dan temuan ini dapat mendukung pengambilan kebijakan adaptasi iklim di sektor pertanian.

Kata Kunci:

Data Mining, Prediksi Suhu, Machine Learning, LightGBM, Agrikultur

DAFTAR ISI

ABSTRAK.....	1
DAFTAR ISI	2
BAB I.....PENDAHULUAN	
4	
1.1 Latar Belakang.....	4
1.2 Tujuan.....	5
1.3 Manfaat.....	5
1.4 Batasan Masalah	6
BAB II	7
PENELITIAN TERKAIT	7
BAB III	12
METODE PENELITIAN	12
3.1 Desain Makalah	12
3.2 Sumber dan Deskripsi Data	12
3.3 Tahapan Analisis.....	13
3.3.1 Analisis Deskriptif	13
3.3.2 Cleaning dan Processing	13
3.3.3 Pemilihan dan pembangunan model	14
3.3.4 Optimasi Model	14
3.3.5 Evaluasi Model.....	14
3.3.6 Prediksi	15
BAB IV.....	15
HASIL DAN PEMBAHASAN	15
4.1 Analisis Deskriptif	15

4.2 Hasil Pemodelan	17
4.3 Hasil Prediksi.....	18
BAB V.....	22
PENUTUP	22
5.1 Kesimpulan	22
5.2 Saran	23
DAFTAR PUSTAKA	24

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perubahan iklim telah menjadi salah satu tantangan global paling mendesak di abad ke-21, dengan peningkatan suhu rata-rata tahunan menjadi indikator utamanya. Peningkatan suhu ini tidak hanya berdampak pada lingkungan secara global, tetapi juga secara spesifik mengancam ketahanan pangan melalui pengaruhnya terhadap sektor agrikultur [1]. Pergeseran pola cuaca, peningkatan frekuensi kejadian cuaca ekstrem, dan perubahan kesesuaian lahan untuk tanaman tertentu menuntut adanya kemampuan prediksi yang akurat. Oleh karena itu, pengembangan model yang andal untuk memprediksi suhu rata-rata tahunan berdasarkan faktor-faktor lingkungan, agrikultur, dan geo-temporal menjadi sangat penting untuk menyusun strategi adaptasi dan mitigasi yang efektif, khususnya dalam konteks tantangan agrikultur global.

Untuk mengatasi masalah prediksi yang kompleks ini, berbagai metode telah diterapkan. Pendekatan statistik tradisional, seperti model *time-series* (misalnya ARIMA), telah lama digunakan, namun seringkali kesulitan menangkap hubungan non-linear yang kompleks antar variabel [2]. Dalam beberapa tahun terakhir, metode *machine learning* telah menunjukkan keunggulan signifikan dalam pemodelan lingkungan. Beberapa penelitian telah berhasil menerapkan berbagai algoritma regresi, mulai dari Random Forest Regressor dan Boosting Regressor, hingga metode ensemble seperti Random Forest dan XGBoost, untuk memprediksi variabel iklim, termasuk suhu [3]. Studi-studi ini menunjukkan bahwa model ML mampu memberikan akurasi yang lebih tinggi dengan memanfaatkan dataset yang besar dan beragam.

Penelitian ini mengadopsi dan membandingkan beberapa model machine learning ensemble terkemuka, yaitu Random Forest, XGBoost, dan LightGBM. Alasan pemilihan metode ini didasarkan pada performa superior mereka yang telah terbukti dalam berbagai kompetisi dan studi kasus, terutama dalam menangani data tabular yang memiliki dimensi tinggi serta hubungan non-linear yang kompleks [4]. Random Forest dikenal karena robustitasnya terhadap *overfitting*, sementara XGBoost dan LightGBM adalah implementasi *gradient boosting* yang sangat efisien dan akurat. Dengan membandingkan model-model ini, kami bertujuan untuk mengidentifikasi

pendekatan yang paling optimal untuk dataset spesifik kami yang mengintegrasikan data agrikultur dan lingkungan.

Kontribusi utama dari penelitian ini ada tiga. Pertama, kami membangun dan melatih beberapa model *machine learning* untuk memprediksi suhu rata-rata tahunan dengan memanfaatkan dataset komprehensif yang mencakup variabel agrikultur (seperti hasil panen dan penggunaan pupuk), data lingkungan (seperti emisi CO2 dan curah hujan), serta data geo-temporal. Kedua, kami melakukan perbandingan performa yang sistematis antara model Random Forest, XGBoost, dan LightGBM untuk menentukan arsitektur yang paling akurat dan andal untuk tugas prediksi ini. Ketiga, kami menyajikan analisis *feature importance* untuk mengidentifikasi faktor-faktor kunci dari data agrikultur dan lingkungan yang memiliki pengaruh paling signifikan terhadap perubahan suhu rata-rata, memberikan wawasan berharga bagi para pembuat kebijakan di sektor pertanian dan lingkungan.

1.2 Tujuan

Tujuan penelitian ini adalah sebagai berikut.

1. Membangun dan melatih model Random forest, XGBoost dan LightGBM untuk memprediksi nilai suhu rata-rata berdasarkan variabel lingkungan, agrikultur, dan geo-temporal.
2. Membandingkan performa model-model tersebut guna menentukan metode yang paling optimal untuk prediksi suhu tahunan.
3. Melakukan analisis *feature importance* untuk mengidentifikasi faktor-faktor yang paling berpengaruh terhadap perubahan suhu rata-rata.
4. Mengevaluasi performa setiap model menggunakan metrik evaluasi untuk memastikan akurasi dan keandalan hasil prediksi.

1.3 Manfaat

Penelitian ini diharapkan dapat memberikan beberapa manfaat praktis dan teoritis, antara lain:

1. Menghasilkan model prediktif yang tervalidasi dan optimal untuk memprediksi Suhu Rata-Rata Tahunan berdasarkan data agrikultur dan lingkungan.

2. Memberikan perbandingan kinerja yang sistematis antara model Random Forest, XGBoost, dan LightGBM, yang dapat menjadi rujukan ilmiah untuk studi kasus serupa di masa depan.
3. Mengidentifikasi faktor-faktor agrikultur dan lingkungan yang paling krusial dalam memengaruhi perubahan suhu, yang dapat membantu memprioritaskan area intervensi.
4. Menyediakan wawasan berbasis data yang dapat digunakan sebagai dasar pengambilan keputusan bagi pembuat kebijakan dan pemangku kepentingan di sektor pertanian untuk merancang strategi adaptasi yang lebih efektif terhadap perubahan iklim.

1.4 Batasan Masalah

Batasan Dataset: Penelitian ini terbatas pada dataset yang disediakan untuk "*Intelecta Cup Data Mining Competition*". Atribut yang digunakan mencakup data geo-temporal (Tahun, Nama Negara, Wilayah), data agrikultur (Jenis Tanaman, Hasil_Panen Ton, Akses Irigasi, Penggunaan Pestisida, Penggunaan Pupuk, Strategi Adaptasi), dan data lingkungan (Total Curah Hujan, Emisi CO₂, Kejadian Cuaca Ekstrem, Indeks Kesehatan Tanah). Data mencakup rentang waktu dari tahun 1990 hingga 2024. Penelitian ini tidak mempertimbangkan faktor-faktor eksternal lain yang mungkin memengaruhi suhu, seperti aktivitas vulkanik, radiasi matahari, atau variabel ekonomi-politik. Penanganan data hilang terbatas pada imputasi modus untuk data kategorikal dan MICE untuk data numerik.

Batasan Metode: Fokus perbandingan model terbatas pada tiga algoritma ensemble berbasis pohon: Random Forest Regressor, XGBoost Regressor, dan LightGBM Regressor. Penelitian ini tidak mencakup eksplorasi model *deep learning* (seperti Jaringan Saraf Tiruan atau LSTM) atau model statistik parametrik lainnya. *Feature engineering* yang dilakukan terbatas pada pembuatan fitur interaksi antar variabel numerik dan fitur polinomial derajat dua.

BAB II

PENELITIAN TERKAIT

Bagian ini mengulas beberapa penelitian sebelumnya yang relevan dengan konteks dataset dan metode yang digunakan dalam studi ini.

2.1 Implementasi Dataset Terkait

Penelitian yang berfokus pada prediksi variabel iklim menggunakan data agrikultur dan lingkungan serupa telah banyak dilakukan. Kumari dan Muthulakshmi, misalnya, mengembangkan model machine learning untuk memprediksi kondisi cuaca, termasuk suhu dan curah hujan, dengan tujuan meningkatkan produksi tanaman [5]. Penelitian mereka menggunakan data cuaca historis dan mengevaluasi berbagai algoritma seperti regresi, decision trees, dan ensemble methods. Hasilnya menunjukkan bahwa model ML mampu mendeteksi pola kompleks dalam data cuaca untuk membantu pengambilan keputusan di bidang pertanian. Kelebihan dari studi ini adalah relevansinya yang tinggi dengan sektor agrikultur, namun tidak secara spesifik membandingkan algoritma gradient boosting canggih yang kami usulkan.

2.2 Implementasi Metode Terkait

Random Forest merupakan algoritma ensemble learning yang bekerja dengan membangun sejumlah besar decision trees secara paralel menggunakan teknik bagging (bootstrap aggregating). Setiap tree dilatih pada subset data yang berbeda yang dipilih secara acak dengan pengembalian, dan setiap split node dalam tree hanya mempertimbangkan subset fitur yang dipilih secara acak. Prediksi akhir diperoleh dengan merata-ratakan hasil prediksi dari seluruh trees untuk kasus regresi. Pendekatan ini mengurangi overfitting dan variance yang sering terjadi pada single decision tree [13].

XGBoost (Extreme Gradient Boosting) adalah implementasi gradient boosting yang sangat efisien dan scalable. Berbeda dengan Random Forest yang membangun trees secara paralel, XGBoost membangun trees secara sekuensial, di mana setiap tree baru berusaha memperbaiki kesalahan dari tree sebelumnya. XGBoost menggunakan

fungsi objektif yang terdiri dari loss function dan regularization term untuk mencegah overfitting. Algoritma ini juga menerapkan teknik seperti tree pruning, handling missing values secara otomatis, dan parallel processing untuk meningkatkan performa komputasi [8].

LightGBM (Light Gradient Boosting Machine) adalah algoritma gradient boosting yang dikembangkan oleh Microsoft dengan fokus pada efisiensi dan kecepatan. LightGBM menggunakan teknik Gradient-based One-Side Sampling (GOSS) untuk memilih data instances yang paling informatif dan Exclusive Feature Bundling (EFB) untuk mengurangi dimensi fitur. Berbeda dengan XGBoost yang menggunakan level-wise tree growth, LightGBM menggunakan leaf-wise tree growth yang tumbuh lebih dalam namun lebih efisien, sehingga cocok untuk dataset berukuran besar [7].

Sebuah studi tentang prediksi kebakaran hutan di Australia—sebuah fenomena yang sangat dipengaruhi oleh iklim—melakukan perbandingan langsung antara model Lasso, Random Forest, LightGBM, dan XGBoost [6]. Penelitian tersebut menemukan bahwa model ensemble (RF, LightGBM, dan XGBoost) secara konsisten mengungguli model linear. Kelebihan utamanya adalah penggunaan Explainable AI (XAI) melalui SHAP untuk mengidentifikasi variabel pendorong utama, seperti kelembaban tanah dan data meteorologi, yang sejalan dengan tujuan kami untuk menemukan feature importance.

Dalam konteks yang lebih spesifik pada perbandingan metode boosting, sebuah studi komparatif berfokus pada penggunaan LightGBM dan XGBoost untuk prediksi curah hujan [7]. Penelitian ini menyoroti bahwa kedua model ensemble tersebut secara signifikan meningkatkan akurasi prediksi dibandingkan dengan metode statistik tradisional. Kelebihan dari penelitian ini adalah perbandingan langsung antara LightGBM dan XGBoost, yang relevan untuk evaluasi model kami. Namun, penelitian tersebut tidak menyertakan Random Forest sebagai model pembanding, sehingga menyisakan celah untuk perbandingan yang lebih komprehensif seperti yang kami lakukan. Demikian pula, penelitian lain yang menerapkan XGBoost untuk prediksi suhu data meteorologi telah mengkonfirmasi keandalan model tersebut dalam menangani data deret waktu iklim [8].

Multiple Imputation by Chained Equations (MICE) adalah teknik imputasi data yang canggih untuk menangani missing values pada dataset multivariat. MICE bekerja dengan pendekatan iteratif di mana setiap variabel dengan missing values dimodelkan secara kondisional menggunakan variabel lain sebagai prediktor. Proses dimulai dengan imputasi awal menggunakan metode sederhana (seperti mean), kemudian untuk setiap variabel yang memiliki missing values, MICE membangun model regresi menggunakan variabel lain yang sudah diimputasi. Proses ini diulang dalam beberapa iterasi hingga konvergen, menghasilkan multiple imputed datasets yang mempertahankan struktur korelasi antar variabel [9], [10].

Penelitian ini menerapkan MICE untuk menangani data yang hilang, sebuah teknik yang juga divalidasi dalam studi lain. Sebagai contoh, penelitian oleh Jünger (2021) melakukan perbandingan metode imputasi untuk data deret waktu meteorologi [9]. Mereka menemukan bahwa MICE secara signifikan lebih akurat daripada metode imputasi sederhana (seperti isian mean/median) karena kemampuannya mempertahankan struktur korelasi antar variabel, yang sangat penting untuk akurasi model prediktif selanjutnya.

MICE dapat menjadi langkah awal yang krusial dalam prediksi suhu rata-rata, khususnya ketika data asli mengandung missing value, agar model regresi yang lebih kompleks dapat bekerja secara optimal [10].

Penelitian terkait prediksi suhu rata-rata telah dilakukan dengan berbagai metode—baik secara langsung pada suhu maupun sebagai bagian dari analisis variabel lain seperti hasil panen atau cuaca. Berbagai algoritma machine learning, teknik imputasi data, serta metode evaluasi performa model digunakan secara luas dan relevan terhadap dataset serupa maupun berbeda, berdasarkan struktur, karakteristik, dan tantangan data [10], [13].

Mean Absolute Error (MAE) mengukur rata-rata dari nilai absolut selisih antara prediksi dan nilai aktual. MAE memberikan interpretasi yang mudah dipahami karena memiliki satuan yang sama dengan variabel target. Root Mean Square Error (RMSE) menghitung akar kuadrat dari rata-rata kuadrat error, memberikan penalti lebih besar

pada error yang besar karena proses pengkuadratan. Mean Absolute Percentage Error (MAPE) mengukur error dalam bentuk persentase, sehingga memudahkan interpretasi skala-independent dan perbandingan antar dataset dengan skala berbeda [11], [12]. Mean Absolute Error (MAE) mengukur rata-rata dari nilai absolut selisih antara prediksi dan nilai aktual:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Root Mean Square Error (RMSE) menghitung akar kuadrat dari rata-rata kuadrat error:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Mean Absolute Percentage Error (MAPE) mengukur error dalam bentuk persentase:

$$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Pada penelitian dengan Long Short-Term Memory (LSTM) untuk prediksi suhu permukaan laut, nilai akurasi model dievaluasi menggunakan MAE dan RMSE, sehingga interpretasi performa dan tingkat kesalahan prediksi dapat dicapai dengan baik. MAPE juga digunakan dalam penelitian prediksi hasil panen dengan model ARIMA berbasis suhu dan curah hujan sebagai indikator utama, membuktikan relevansi nilai error dalam analisis dan perbandingan antar model. Ketiga metrik ini (MAPE, MAE, dan RMSE) menjadi standar penilaian dalam regresi prediksi suhu [11], [12].

Analisis feature importance merupakan komponen penting dalam model regresi dan ensemble learning seperti Random Forest, XGBoost, dan LightGBM, terutama dalam menjelaskan faktor yang paling memberi pengaruh terhadap hasil prediksi suhu rata-rata. Dalam Random Forest, feature importance dihitung berdasarkan rata-rata penurunan impurity (Gini importance) atau penurunan akurasi ketika fitur tersebut di-permutasi. Pada XGBoost dan LightGBM, importance dapat dihitung berdasarkan gain (peningkatan akurasi dari split), cover (jumlah observasi yang terpengaruh), atau

frekuensi penggunaan fitur dalam trees. Keberadaan fitur ini mendorong interpretasi lebih baik bagi peneliti dan praktisi untuk menentukan variabel utama yang berdampak pada akurasi model [13].

Random Forest Regressor telah terbukti efektif digunakan dalam analisis hasil panen yang dipengaruhi oleh variabel suhu, curah hujan, dan kelembapan, khususnya pada wilayah pertanian di Sumatera. Selain itu, model ensemble lain seperti XGBoost dan LightGBM juga diimplementasikan karena sifatnya yang mampu menangani data berukuran besar, nonlinearitas, dan multivariat—memberikan performa prediksi tinggi pada suhu dan hasil panen. Pada regresor berbasis ensemble ini, feature importance dapat membantu dalam pemilihan variabel prediktor yang paling relevan untuk suhu rata-rata [13].


Beberapa penelitian tidak menggunakan dataset yang sama namun tetap relevan bila karakteristik data mirip—misalnya, pengaruh suhu pada hasil panen atau suhu harian di lokasi yang berbeda. Dengan demikian, penggunaan metode MICE, Random Forest, XGBoost, LightGBM, serta evaluasi MAPE, MAE, dan RMSE tetap dapat diterapkan secara fleksibel dan menghasilkan model prediksi suhu yang robust sesuai kebutuhan penelitian [10]–[13].

BAB III

METODE PENELITIAN

3.1 Desain Makalah

Makalah ini menggunakan pendekatan data mining dan machine learning untuk menganalisis dampak perubahan iklim terhadap pertanian global. Proses analisis dilakukan secara bertahap mulai dari eksplorasi data, preprocessing, pemodelan, hingga evaluasi model terbaik. Diagram alur proses disajikan pada Gambar 1, yang menunjukkan keseluruhan tahapan mulai dari pembagian data hingga menghasilkan model akhir untuk prediksi suhu rata-rata.



Gambar 1. Alur kerja pembangunan model

3.2 Sumber dan Deskripsi Data

Data yang digunakan dalam makalah ini diperoleh dari perlombaan Kaggle Intellecta Cup Data Mining Competition, yang berfokus pada analisis dampak perubahan iklim terhadap pertanian global. Dataset ini dirancang untuk memberikan wawasan kepada peneliti, data scientist, serta pembuat kebijakan dalam memahami bagaimana variasi kondisi iklim dapat memengaruhi produktivitas pertanian di berbagai wilayah dunia.

Secara khusus, data ini difokuskan untuk memprediksi suhu rata-rata sebagai indikator utama perubahan iklim, dengan mempertimbangkan berbagai faktor lingkungan dan praktik pertanian yang berkontribusi terhadap dinamika suhu tersebut.

Tabel 1. Variabel data

Nama Variabel	Tipe Data	Peran
Tahun	Numerik	Prediktor
Nama Negara	Kategorikal	Prediktor
Wilayah	Kategorikal	Prediktor
Jenis Tanaman	Kategorikal	Prediktor
Total Curah Hujan mm	Numerik	Prediktor
Emisi CO2 JT Ton	Numerik	Prediktor
Hasil Panen Ton per HA	Numerik	Prediktor
Kejadian Cuaca Ekstrim	Numerik	Prediktor
Akses Irigasi	Numerik	Prediktor
Penggunaan Pestisida KG per HA	Numerik	Prediktor
Penggunaan Pupuk KG per HA	Numerik	Prediktor
Indeks Kesehatan Tanah	Numerik	Prediktor
Strategi Adaptasi	Kategorikal	Prediktor
Suhu Rata Rata C	Numerik	Target Variable

3.3 Tahapan Analisis

Seluruh proses dibagi menjadi beberapa tahapan yang mudah dipahami berikut.

3.3.1 Analisis Deskriptif

Langkah awal adalah melakukan analisis deskriptif guna memeriksa struktur dataset untuk memahami bentuk dan kualitas data. Kegiatan ini meliputi melihat contoh baris data, menghitung jumlah nilai kosong per kolom, dan meninjau ringkasan statistik sederhana untuk mengetahui rentang nilai dan adanya *outlier*. Tujuan utamanya adalah menentukan masalah data yang perlu ditangani pada tahap *cleaning*.

3.3.2 Cleaning dan Processing

Setelah pemeriksaan, data dibersihkan dan diproses agar siap dipakai oleh model:

- Penanganan *missing values*: nilai kosong pada kolom kategorikal diisi berdasarkan nilai modus yang paling representatif, untuk kolom numerik digunakan metode MICE (*Multiple Imputation by Chained Equations*) yang mempertimbangkan informasi dari kolom lain supaya pengisian lebih akurat.
- Transformasi skala: beberapa fitur numerik disesuaikan skalanya agar tidak mendominasi pelatihan model; kolom temporal (Tahun) diperlakukan terpisah sesuai kebutuhan.
- Pengecekan akhir: setelah *cleaning*, dilakukan pemeriksaan kembali untuk memastikan tidak ada nilai yang tidak sesuai dan bahwa data siap untuk tahap pemodelan.

3.3.3 Pemilihan dan pembangunan model

Beberapa jenis model berbasis regresi seperti Random Forest, XGBoost, dan LightGBM dipilih untuk dibandingkan berdasarkan karakter data. Setiap model dilatih pada data latih dan dievaluasi awal pada data validasi untuk memperoleh gambaran performa relatif. Pendekatan ini bertujuan menemukan model yang paling cocok untuk memprediksi suhu rata-rata dari kumpulan fitur yang tersedia.

3.3.4 Optimasi Model

Model yang menunjukkan kinerja menjanjikan kemudian disempurnakan dengan menyesuaikan pengaturan internalnya (*hyperparameter tuning*). Penyempurnaan dilakukan dengan mengevaluasi kombinasi pengaturan berbeda dan memilih yang memberikan kinerja terbaik. Selain itu, *cross-validation* digunakan untuk memastikan hasil tidak bergantung pada satu pembagian data saja sehingga penilaian model lebih stabil dan dapat digeneralisasi.

3.3.5 Evaluasi Model

Evaluasi model dilakukan dengan metrik yang relevan untuk masalah regresi, antara lain adalah MAE, RMSE, dan MAPE. Kemudian dilihat *feature importance* untuk menganalisis variabel mana yang berpengaruh paling besar untuk suhu rata-rata.


3.3.6 Prediksi

Setelah memperoleh model terbaik, langkah terakhir adalah melakukan prediksi terhadap data test data untuk menilai kinerja dan kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

BAB IV

HASIL DAN PEMBAHASAN

4.1 Analisis Deskriptif




Gambar 2. Pariplot variabel numerik

Pair Plot memberikan gambaran menyeluruh mengenai distribusi dan hubungan antar fitur numerik berdasarkan kategori strategi adaptasi. Pada bagian diagonal, ditampilkan histogram yang memperlihatkan distribusi setiap fitur numerik yang

dibedakan berdasarkan warna strategi adaptasi. Melalui pair plot, kita dapat mengamati apakah distribusi nilai antar strategi adaptasi menunjukkan perbedaan yang signifikan, misalnya apakah negara dengan strategi "Manajemen Air" memiliki curah hujan yang cenderung lebih tinggi atau lebih rendah dibandingkan dengan "Tanpa Adaptasi".

Sementara itu, pada bagian luar diagonal, scatter plot menampilkan hubungan antar pasangan fitur numerik, di mana setiap strategi adaptasi diwakili oleh warna yang berbeda. Hal ini memungkinkan kita untuk mengidentifikasi adanya perbedaan pola hubungan baik linear maupun non-linear antara dua fitur pada masing-masing strategi adaptasi. Sebagai contoh, tren antara Emisi CO2 dan Suhu Rata Rata mungkin berbeda antara "Pertanian Organik" dan "Tanpa Adaptasi".

Selain itu, keberadaan kluster atau pengelompokan titik-titik berdasarkan warna dapat mengindikasikan keterkaitan antara strategi adaptasi dengan kombinasi nilai-nilai tertentu dari fitur numerik. Pair Plot juga membantu dalam mendeteksi outlier pada setiap kategori, di mana titik-titik yang menyimpang dari pola utama dapat menunjukkan adanya kategori strategi adaptasi yang lebih sering terkait dengan kejadian ekstrem tersebut.



Gambar 3. Heatmap korelasi

Hasil analisis korelasi menunjukkan bahwa variabel Hasil Panen memiliki korelasi positif paling kuat dengan Suhu Rata Rata, dengan nilai sekitar 0,27. Meskipun nilai ini tidak terlalu tinggi, hubungan tersebut mengindikasikan adanya kecenderungan bahwa

peningkatan suhu rata-rata dapat berkaitan dengan peningkatan hasil panen per hektar, atau sebaliknya. Sementara itu, variabel Akses_Irigasi menunjukkan korelasi negatif yang lemah terhadap suhu rata-rata (sekitar -0,017), begitu pula dengan Penggunaan Pupuk yang memiliki korelasi negatif lemah sebesar -0,021. Adapun variabel lainnya seperti Total Curah Hujan, Emisi CO₂, Kejadian Cuaca Ekstrem, Penggunaan Pestisida, dan Indeks Kesehatan Tanah memperlihatkan hubungan linear yang sangat lemah dengan Suhu Rata Rata, dengan nilai korelasi yang mendekati nol. Hal ini menunjukkan bahwa dalam konteks hubungan linear, kontribusi langsung fitur-fitur tersebut terhadap suhu rata-rata relatif kecil.

Analisis korelasi antar fitur prediktor menunjukkan bahwa tidak terdapat pasangan variabel yang memiliki korelasi linear tinggi (mendekati 1 atau -1). Dengan demikian, multikolinearitas yang kuat tampaknya bukan merupakan masalah utama dalam model yang menggunakan fitur-fitur numerik ini. Beberapa pasangan variabel, seperti Emisi CO₂ dengan Penggunaan Pestisida serta Akses Irigasi dengan Indeks Kesehatan Tanah, menunjukkan korelasi yang sangat lemah, yang menegaskan bahwa hubungan linear antar variabel prediktor cenderung rendah dan tidak saling memengaruhi secara signifikan dalam konteks prediksi suhu rata-rata.

4.2 Hasil Pemodelan

Tabel 2. Performa model prediksi suhu rata rata

Model	MAE	RMSE	MAPE
Random Forest	8.955679	10.60585	573.2541
XGBoost	9.397795	11.31024	576.1334
LightGBM	8.964470	10.59020	575.0393
Random Forest + Optimasi	0.816511	0.981896	394.3544
XGBoost + Optimasi	0.785177	0.932076	371.7356
LightGBM + Optimasi	0.790338	0.941162	329.0040

Tabel 2 menunjukkan performa tiga model utama Random Forest, XGBoost, dan LightGBM baik sebelum maupun setelah dilakukan proses optimasi melalui *hyperparameter tuning* dan *cross-validation*. Evaluasi dilakukan menggunakan tiga metrik utama, yaitu MAE, RMSE, dan MAPE, yang masing-masing mengukur tingkat kesalahan prediksi model dari sudut pandang yang berbeda.

Sebelum dilakukan optimasi, ketiga model memiliki nilai kesalahan yang relatif tinggi, dengan MAE berkisar antara 8.95–9.40, RMSE antara 10.59–11.31, dan MAPE mencapai lebih dari 570%. Nilai-nilai tersebut menunjukkan bahwa model belum mampu memprediksi suhu rata-rata dengan baik, kemungkinan karena penggunaan parameter default yang belum sesuai dengan karakteristik data.


Setelah dilakukan hyperparameter tuning menggunakan teknik cross-validation, kinerja seluruh model mengalami peningkatan yang signifikan. Nilai MAE menurun drastis hingga di bawah 1.0, dan RMSE berkurang menjadi sekitar 0.93–0.98, menandakan bahwa rata-rata selisih antara nilai prediksi dan nilai aktual menjadi jauh lebih kecil. Selain itu, nilai MAPE juga menurun tajam, khususnya pada model LightGBM + Optimasi yang mencapai 329.0040, menjadikannya model dengan performa terbaik di antara ketiganya.

Peningkatan ini terjadi karena proses hyperparameter tuning memungkinkan pencarian kombinasi parameter yang optimal, seperti jumlah pohon (*n estimators*), kedalaman pohon (*max depth*), laju pembelajaran (*learning rate*), dan jumlah fitur yang digunakan pada setiap split. Dengan kombinasi parameter yang lebih sesuai, model menjadi lebih mampu menangkap pola kompleks dalam data tanpa mengalami overfitting. Selain itu, penggunaan *cross-validation* membantu memastikan bahwa performa yang diperoleh stabil dan tidak hanya berlaku untuk data latih tertentu.

Secara keseluruhan, hasil ini menunjukkan bahwa proses optimasi parameter sangat berpengaruh terhadap peningkatan akurasi model prediksi suhu rata-rata. Dari ketiga model yang diuji, LightGBM dengan optimasi memberikan hasil paling optimal, menunjukkan keseimbangan antara bias dan variansi yang baik serta efisiensi komputasi yang tinggi.

4.3 Hasil Prediksi

Distribusi suhu rata-rata divisualisasikan melalui histogram untuk melihat pola penyebaran nilai pada dataset. Gambar berikut menunjukkan sebaran nilai suhu rata-rata dalam skala derajat Celsius.



Gambar 4. Histogram prediksi suhu rata rata


Gambar di atas menunjukkan distribusi data suhu rata-rata pada skala asli. Terlihat bahwa data tidak sepenuhnya berdistribusi normal, melainkan memiliki pola multimodal terdapat beberapa puncak (*mode*) pada rentang nilai tertentu. Puncak utama berada di sekitar 15°C, yang menandakan bahwa sebagian besar observasi memiliki suhu rata-rata di kisaran tersebut. Selain itu, terdapat kelompok data lain yang cukup signifikan di sekitar 5°C dan 22–24°C, yang mengindikasikan adanya variasi suhu antar wilayah atau periode waktu tertentu.

Distribusi ini juga tampak sedikit miring ke kanan (*right-skewed*), karena masih terdapat sejumlah kecil data dengan suhu rendah (mendekati 0°C), namun lebih banyak data yang berkumpul pada suhu menengah hingga tinggi. Variasi bentuk distribusi ini bisa mencerminkan perbedaan kondisi iklim antar lokasi pengamatan atau faktor musiman yang memengaruhi suhu rata-rata.

Secara keseluruhan, pola histogram ini menunjukkan bahwa data suhu tidak terdistribusi normal sempurna, sehingga pemilihan model prediksi non-linear seperti LightGBM memang lebih tepat digunakan dibandingkan model linear konvensional, karena dapat menangkap pola yang kompleks dalam data suhu tersebut.

Setelah memprediksi, langkah selanjutnya adalah melakukan analisis fitur (*feature importance*) untuk mengetahui sejauh mana setiap variabel input berkontribusi terhadap hasil prediksi suhu rata-rata. Analisis ini bertujuan untuk mengidentifikasi fitur-fitur yang paling berpengaruh dalam menentukan variasi suhu, sehingga dapat

memberikan wawasan mengenai faktor-faktor utama yang memengaruhi model. Dengan mengetahui fitur mana yang memiliki bobot penting terbesar, hasil pemodelan tidak hanya menghasilkan prediksi yang akurat, tetapi juga dapat diinterpretasikan secara lebih mendalam dari sisi faktor penyebabnya. Gambar berikut menampilkan hasil analisis *feature importance* dari model terbaik yang telah diperoleh.



Gambar 5. 10 *fiture importance* dari model terbaik

Berdasarkan grafik, variabel “Hasil Panen Ton” menempati posisi teratas dengan nilai *importance* tertinggi, menunjukkan bahwa produktivitas hasil panen memiliki hubungan yang kuat dengan suhu rata-rata di wilayah pengamatan. Hal ini dapat dijelaskan karena suhu merupakan salah satu faktor iklim utama yang memengaruhi pertumbuhan tanaman, sehingga perubahan suhu dapat secara langsung berdampak pada hasil panen.

Selanjutnya, variabel “Emisi CO2” dan “Indeks Kesehatan Tanah” juga memiliki nilai kepentingan yang cukup tinggi. Kedua variabel ini mencerminkan aspek lingkungan dan kualitas lahan yang erat kaitannya dengan kondisi iklim dan suhu di suatu wilayah. Semakin tinggi emisi karbon, misalnya, dapat berkaitan dengan peningkatan suhu akibat efek rumah kaca

Fitur-fitur seperti “Penggunaan Pupuk KG”, “Total Curah Hujan”, dan “Penggunaan Pestisida KG” juga menunjukkan kontribusi moderat terhadap model. Hal ini mengindikasikan bahwa faktor pengelolaan lahan dan kondisi curah hujan turut memengaruhi variasi suhu rata-rata secara tidak langsung. Sementara itu, variabel “Akses Irigasi”, “Wilayah”, dan “Tahun” memiliki nilai kepentingan yang lebih rendah,

menunjukkan bahwa pengaruhnya terhadap prediksi suhu relatif kecil dibandingkan faktor biofisik dan lingkungan lainnya.

Secara keseluruhan, hasil analisis feature importance ini menegaskan bahwa faktor lingkungan dan aktivitas pertanian merupakan determinan utama dalam pembentukan variasi suhu rata-rata. Temuan ini dapat menjadi dasar bagi pengambilan kebijakan dalam pengelolaan pertanian berkelanjutan yang mempertimbangkan kondisi iklim dan dampaknya terhadap produktivitas lahan.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian mengenai prediksi suhu rata-rata tahunan menggunakan model ensemble machine learning dengan data lingkungan, agrikultur, dan geo-temporal dari kompetisi Intellecta Cup Data Mining Competition, diperoleh beberapa kesimpulan utama sebagai berikut:

1. Model *machine learning* terbukti mampu memprediksi suhu rata-rata tahunan dengan akurasi yang baik setelah dilakukan proses *hyperparameter* tuning dan *cross-validation*.
2. Di antara tiga model yang dibandingkan Random Forest, XGBoost, dan LightGBM model LightGBM dengan optimasi memberikan performa terbaik dengan nilai MAE sebesar 0.79, RMSE sebesar 0.94, dan MAPE sebesar 329.00, menandakan kemampuan prediksi yang paling stabil dan akurat.
3. Proses optimasi model memiliki dampak signifikan terhadap peningkatan kinerja semua model. Sebelum tuning, tingkat kesalahan prediksi masih tinggi ($MAE > 8$), namun setelah tuning nilai kesalahan turun drastis hingga di bawah 1. Hal ini menunjukkan pentingnya tahap optimasi dalam memperoleh model yang efisien dan sesuai dengan karakteristik data.
4. Berdasarkan analisis feature importance, variabel yang paling berpengaruh terhadap suhu rata-rata adalah Hasil Panen, Emisi CO₂, dan Indeks Kesehatan Tanah.
5. Temuan ini menegaskan adanya keterkaitan erat antara aktivitas agrikultur dan kondisi lingkungan terhadap dinamika perubahan suhu global.
6. Distribusi data suhu yang bersifat non-linear dan multimodal menunjukkan bahwa pendekatan non-linear seperti LightGBM lebih efektif dibandingkan model linear tradisional. Model ini mampu menangkap hubungan kompleks antara variabel lingkungan dan agrikultur yang saling berinteraksi dalam memengaruhi suhu rata-rata.
7. Secara keseluruhan, penelitian ini menunjukkan bahwa penggabungan data lintas sektor (lingkungan, agrikultur, dan geo-temporal) dengan pendekatan ensemble

machine learning dapat menghasilkan sistem prediktif yang kuat dan dapat diandalkan untuk mendukung analisis perubahan iklim serta perencanaan adaptasi pertanian yang lebih berkelanjutan.

5.2 Saran

Adapun yang menjadi saran dari makalah ini adalah:

1. Pengayaan dataset:

Untuk meningkatkan generalisasi model, penelitian berikutnya disarankan untuk menambahkan variabel eksternal seperti radiasi matahari, aktivitas vulkanik, kelembapan udara, dan faktor sosio-ekonomi agar prediksi suhu lebih komprehensif dan realistis.

2. Eksplorasi model lain:

Dapat dipertimbangkan penggunaan model *Deep Learning* seperti *Neural Network* atau LSTM untuk menangkap pola temporal jangka panjang dalam data iklim tahunan, yang mungkin tidak sepenuhnya tertangkap oleh model berbasis pohon.

3. Pendekatan interpretabilitas lanjut:

Analisis fitur dapat diperluas dengan metode interpretasi modern seperti SHAP (*SHapley Additive exPlanations*) atau LIME, guna memahami lebih mendalam hubungan sebab-akibat antara variabel input dan prediksi suhu.

4. Validasi spasial dan temporal:

Disarankan untuk menguji model pada data wilayah atau tahun yang berbeda (misalnya *out-of-sample validation*) agar dapat menilai sejauh mana model mampu beradaptasi terhadap variasi iklim di lokasi dan waktu yang berbeda.

5. Pemanfaatan hasil untuk kebijakan:

Hasil penelitian ini dapat dijadikan dasar bagi pembuat kebijakan di bidang pertanian dan lingkungan untuk merumuskan strategi mitigasi dan adaptasi berbasis data, seperti pengelolaan lahan yang ramah iklim dan pengendalian emisi karbon dari sektor agrikultur.

DAFTAR PUSTAKA

- [1] IPCC, *Climate Change and Land: an IPCC special report on climate change, desertification, land degradation, sustainable land management, food security, and greenhouse gas fluxes in terrestrial ecosystems*, P. R. Shukla, J. Skea, E. Calvo Buendia, V. Masson-Delmotte, H.-O. Pörtner, D. C. Roberts, P. Zhai, R. Slade, S. Connors, R. van Diemen, M. Ferrat, E. Haughey, S. Luz, S. Neogi, M. Pathak, J. Petzold, J. Portugal Pereira, P. Vyas, E. Huntley, K. Kissick, M. Belkacemi, and J. Malley, Eds. In press, 2019.
- [2] H. Ghous, A. Malik, Z. Ahmad, U. Jabeen, and M. Khawar, "Climate Change Forecasting Using Time Series Techniques: A Comprehensive Review," *Southern Journal of Computer Science*, vol. 1, no. 1, pp. 37–61, 2025.
- [3] A. Hussain, F. U. Maheri, I. Islam, Shanze, M. Aqeel, P. Fatima, N. Kumari, H. Saeed, and A. Abbasi, "The Role of Machine Learning in Climate Change Modeling and Prediction: A Comprehensive Review," *Global Scientific and Academic Research Journal of Multidisciplinary Studies*, vol. 4, no. 1, pp. 42–55, Jan. 2025, doi: 10.5281/zenodo.14712488.
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," in *Proc. 31st Conf. Neural Inf. Process. Syst. (NIPS)*, Long Beach, CA, USA, 2017, pp. 3146–3154.
- [5] S. Kumari and P. Muthulakshmi, "Predicting Weather Conditions Using Machine Learning for Improving Crop Production," in *AI Applications for Business, Medical, and Agricultural Sustainability*, pp. 267–302, Mar. 2024, doi: 10.4018/979-8-3693-5266-3.ch010
- [6] Z. Abohaia, A. Elkhoully, M. E. Barachi, and O. Al-Khatib, "Explainable AI-Driven Wildfire Prediction in Australia: SHAP and Feature Importance to Identify Environmental Drivers in the Age of Climate Change," *Fire*, vol. 8, no. 11, p. 421, Oct. 2025, doi: 10.3390/fire8110421.

- [7] M. F. Ramadhan, M. R. A. Siregar, and M. R. Lubis, "Enhanced Rainfall Forecasting: A Comparative Study of LightGBM and XGBoost Model," *Zenodo*, Oct. 2025. [Online]. Available: <https://zenodo.org/records/15239519>
- [8] W. Xue, Y. Gao, L. Chen, and E. Lv, "Research on a Temperature Prediction Model for Meteorological Data Integrating XGBoost and MLP," in *Artificial Intelligence and Machine Learning*, vol. 252, pp. 252–264, Jul. 2025, doi: 10.1007/978-981-96-7188-5_22.
- [9] C. Yozgatligil, S. Aslan, C. Iyigun, and I. Batmaz, "Comparison of missing value imputation methods in time series: The case of Turkish meteorological data," *Theoretical and Applied Climatology*, vol. 112, no. 1–2, pp. 143–167, Apr. 2013, doi: 10.1007/s00704-012-0723-x.
- [10] A. R. Mailuhu et al., "Prediksi Suhu Udara Rata-Rata Harian dengan Metode Regresi Linier di Kota Ambon," *Tanah Goyang: Jurnal Sains dan Teknologi*, vol. 2, no. 2, pp. 81-90, 2023. [Online]. Available: <https://ojs3.unpatti.ac.id/index.php/tanahgoyang/article/view/9081>
- [11] N. K. Sari et al., "Perbandingan Model Prediksi Suhu Permukaan Laut Menggunakan Smoothing dan Long Short-Term Memory," *Algoritma*, vol. 7, no. 1, pp. 24–31, 2025. [Online]. Available: <https://jurnal.itg.ac.id/index.php/algoritma/article/view/2113>
- [12] K. Praditya et al., "Prediksi hasil panen padi berdasarkan data curah hujan, suhu, dan kelembapan dengan metode ARIMA," *SAINTEK*, vol. 8, no. 2, pp. 213–220, 2025. [Online]. Available: <https://journal.upgripnk.ac.id/index.php/saintek/article/view/9292>
- [12] E. Wahyuni et al., "Prediksi Hasil Panen Tanaman Pangan Sumatera dengan Metode Machine Learning," *Digitech Journal*, vol. 6, no. 3, pp. 38-46, 2023. [Online]. Available: <https://jurnal.itscience.org/index.php/digitech/article/view/2852>