

Integrasi *Machine Learning* dan *Computer Vision* pada Data Grafik Historis untuk Meningkatkan Akurasi Prediksi Curah Hujan

Musliadi
Departemen Statistika
Universitas Syiah Kuala
Banda Aceh, Indonesia
musliadi6@mhs.uks.ac.id

Muhammad Zulkarnaini
Departemen Statistika
Universitas Syiah Kuala
Banda Aceh, Indonesia
zul22@mhs.uks.ac.id

'Asalul Musaffa
Departemen Statistika
Universitas Syiah Kuala
Banda Aceh, Indonesia
asalul@mhs.usk.ac.id

Abstrak—Prediksi curah hujan ekstrem di wilayah perkotaan tropis seperti Singapura merupakan tantangan signifikan yang diperparah oleh perubahan iklim. Informasi meteorologi historis dalam format visual, seperti grafik pada laporan lama, merupakan sumber daya berharga yang sering terabaikan. Penelitian ini bertujuan untuk meningkatkan akurasi prediksi curah hujan dengan mengembangkan dan memvalidasi sebuah kerangka kerja untuk mengintegrasikan data historis tersebut. Metode yang digunakan adalah proses penyelamatan data (*data rescue*) berbasis *Computer Vision* untuk mengekstraksi data deret waktu dari arsip grafik. Data yang telah diekstraksi kemudian digabungkan dengan data meteorologi standar untuk melatih dan membandingkan tiga model *Machine Learning* yaitu Linear Regression, XGBoost, dan Gradient Boosting Regression pada data dari 44 stasiun cuaca. Hasil penelitian menunjukkan bahwa model Gradient Boosting Regression secara konsisten memberikan kinerja terbaik di seluruh stasiun, dengan nilai MSE terendah dan R^2 tertinggi. Validasi visual juga mengonfirmasi kemampuan model untuk mereplikasi pola curah hujan aktual dengan akurasi tinggi. Penelitian ini menghasilkan sebuah alur kerja yang terbukti efektif untuk mengubah data arsip yang tidak terstruktur menjadi aset berharga untuk pemodelan prediktif. Kerangka kerja ini memiliki implikasi praktis yang signifikan untuk meningkatkan sistem peringatan dini dan relevan untuk diterapkan oleh lembaga meteorologi di kawasan Asia Tenggara, termasuk BMKG di Indonesia.

Kata kunci—*Machine Learning*, *Data Rescue*, *Data Deret Waktu*.

I. PENDAHULUAN

Dalam beberapa dekade terakhir, frekuensi dan intensitas kejadian cuaca ekstrem di dunia mengalami peningkatan yang signifikan, yang sebagian besar dipicu oleh perubahan iklim dan penguatan siklus hidrologi [1], [2]. Singapura, meskipun memiliki wilayah daratan yang kecil, menghadapi tantangan besar dalam memprakirakan kondisi cuaca lokal secara akurat akibat kepadatan infrastruktur perkotaan dan variasi iklim mikro yang tinggi [3]. Kejadian hujan dengan intensitas tinggi dan durasi singkat sering memicu banjir lokal, yang berdampak pada infrastruktur, transportasi, dan keselamatan publik [4]. Oleh karena itu, perkiraan yang akurat dan tepat waktu menjadi kunci untuk meningkatkan ketahanan di lingkungan perkotaan tropis.

Meteorological Service Singapore (MSS) mengoperasikan jaringan observasi yang padat dengan 44 stasiun cuaca yang tersebar di seluruh pulau, mengumpulkan data harian sejak 1980 [5]. Data ini mencakup parameter penting seperti puncak curah hujan sub-jam, total curah hujan harian, suhu ekstrem, dan kecepatan angin. Namun, meskipun memiliki sistem pemantauan yang luas, prediksi hujan lebat tetap menjadi tantangan karena interaksi kompleks antara kondisi atmosfer skala besar, sistem konvektif mesoskal, dan efek pulau panas perkotaan [6], [7].

Selain data numerik konvensional, terdapat arsip besar informasi meteorologi historis dalam format visual seperti grafik garis yang terdapat pada laporan PDF, dokumen hasil pemindaian, dan atlas cuaca historis [8]. Data semacam ini sering diabaikan dalam perkiraan operasional, padahal dapat diubah menjadi format numerik menggunakan teknologi *optical character recognition* (OCR) dan *computer vision* [9]. Integrasi data yang diekstrak dari grafik dengan catatan meteorologis konvensional dapat memperpanjang rentang historis data pelatihan dan berpotensi meningkatkan kemampuan generalisasi model prediksi hujan ekstrem.

Bagi Indonesia, yang memiliki kondisi iklim maritim tropis serupa, pendekatan ini sangat relevan. Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) memiliki arsip data cuaca historis yang sebagian besar belum tersedia dalam format yang dapat diolah mesin [10]. Pemanfaatan data deret waktu hasil digitalisasi untuk Singapura dan Indonesia dapat mendukung pengembangan sistem perkiraan berbasis *machine learning* (ML) yang mampu memberikan prediksi curah hujan berskala lokal dengan presisi lebih tinggi, khususnya di wilayah rawan bencana seperti Jakarta, Bandung, dan Medan [11], [12].

Penelitian ini mengkaji integrasi *machine learning* dan *computer vision* pada data curah hujan historis berbasis grafik dengan parameter meteorologis standar untuk meningkatkan akurasi perkiraan hujan lebat di Singapura, dengan kerangka metodologi yang dapat diadaptasi untuk lingkungan perkotaan di Indonesia. Dengan menggabungkan sains data, *computer vision*, dan meteorologi tropis, studi ini bertujuan menjembatani kesenjangan antara data arsip dan perkiraan di masa yang mendatang, sehingga dapat meningkatkan ketahanan iklim di kota-kota Asia Tenggara.

II. METODOLOGI

A. Pemahaman Data

Data cuaca harian diperoleh dari 44 stasiun pengamatan di Singapura, mencakup periode 1980-2025. Dataset terdiri atas variabel *independent*: *Highest 30 min Rainfall (mm)*, *Highest 60 min Rainfall (mm)*, *Highest 120 min Rainfall (mm)*, *Daily Rainfall Total (mm)*, *Mean Temperature (°C)*, *Maximum Temperature (°C)*, *Minimum Temperature (°C)*, *Mean Wind Speed (km/h)*, dan *Max Wind Speed (km/h)* dalam bentuk numerik. Sedangkan *Daily Rainfall Total (mm)*. Sedangkan variabel *dependent* yaitu *Daily Rainfall Total (mm)* dalam bentuk grafik.

B. Pra-pemrosesan Data

Ekstraksi dari berkas CSV dimulai dengan pengumpulan seluruh berkas CSV per stasiun menjadi satu repositori terpusat. Setiap berkas diproses melalui *pipeline* otomatis yang melakukan beberapa tahap pembersihan dan standarisasi. Tahap penting pertama adalah pembersihan data, di mana karakter non-numerik seperti simbol-simbol yang terkadang muncul pada data historis, dihapus dari kolom numerik. Selanjutnya, untuk mengatasi masalah data kosong atau *missing values*, nilai-nilai tersebut diidentifikasi lalu diimputasi menggunakan median bulanan. Metode ini dipilih untuk mempertahankan siklus musiman data. Setelah data bersih, dilakukan normalisasi format tanggal ke YYYY-MM-DD dan konversi tipe data ke float. Sebagai tambahan, dilakukan deteksi *outlier* menggunakan IQR untuk meminimalkan pengaruh pengukuran ekstrem yang keliru. Terakhir, fitur turunan seperti Year dan Month ditambahkan sebelum dataset akhir disimpan.

Ekstraksi dari data grafik dilakukan dengan membaca berkas citra PNG per tahun dan melakukan transformasi warna ke ruang HSV untuk memudahkan segmentasi. Dalam implementasi ini digunakan masker rentang HSV untuk mengisolasi kurva berwarna biru dan masker terpisah untuk mendeteksi elemen sumbu berwarna hitam. Kontur pada masker sumbu dianalisis untuk menentukan posisi dan rentang sumbu-x (*bounding rectangle*) yang menjadi acuan pemetaan koordinat piksel ke indeks hari. Titik-titik kurva diperoleh dengan mengambil piksel berwarna biru lalu mengonversi koordinat matriks menjadi pasangan (x, y) dalam format (kolom, baris), titik-titik tersebut difilter agar hanya mencakup rentang x yang berada di antara batas sumbu yang terdeteksi. Pemetaan sumbu-x ke tanggal dilakukan secara linear, Indeks hari dihitung dari posisi relatif x terhadap rentang sumbu dikalikan dengan jumlah baris data dalam CSV tahunan, kemudian diklipp dan diubah menjadi tanggal pada kolom Date sumber CSV. Untuk curah hujan harian, nilai piksel y dinormalisasi terhadap rentang piksel kurva (y_min, y_max) dan kemudian diskalakan ke satuan milimeter menggunakan nilai puncak tahunan sebagai batas atas grafis; nilai yang diperoleh dirata-ratakan per tanggal, digabungkan dengan daftar tanggal penuh, dan lubang data diisi melalui interpolasi *linier* sebelum penyimpanan dan visualisasi.

C. Pengembangan Model

Data dibagi secara kronologis menjadi set pelatihan (1980-2023) dan set pengujian (2024-2025) untuk memastikan evaluasi model merefleksikan kondisi prediksi nyata tanpa kebocoran informasi temporal. Pada setiap stasiun pengamatan,

yang berjumlah 44 stasiun, ketiga model dilatih dan diuji secara terpisah. Sebagai langkah awal, dipelajari model *Linear Regression* untuk menetapkan tolak ukur kinerja sederhana dan mengidentifikasi kontribusi *linier* antar fitur. Selanjutnya dipertimbangkan model *ensemble non-linear*, yaitu *Random Forest*, yang digunakan untuk menangkap interaksi variabel dan efek *non-linear* tanpa asumsi distribusi residual. Untuk performa lebih lanjut, model *Gradient Boosting Regression* diimplementasikan karena kemampuannya mengatasi heterogenitas sinyal dan kepekaan terhadap fitur dengan kontribusi lemah.

D. Evaluasi Model

Kinerja model dievaluasi menggunakan tiga metrik utama: *Mean Absolute Percentage Error (MAPE)*, *Coefficient of Determination (R²)*, dan *Mean Squared Error (MSE)*. Untuk stasiun ke- j ($j=1, \dots, J$) dengan N_j observasi evaluasi, nilai aktual dan prediksi dinyatakan sebagai $y_i^{(j)}$ dan $\hat{y}_i^{(j)}$ untuk $i = 1, \dots, N_j$. Simbol rata-rata actual per stasiun ditulis sebagai:

$$\bar{y}_i^{(j)} = \frac{1}{N_j} \sum_{i=1}^{N_j} y_i^{(j)} \quad (1)$$

Semua metrik dihitung untuk setiap model pada masing-masing dari 44 stasiun, dengan tujuan evaluasi untuk mengukur akurasi dan karakteristik kesalahan tiap model pada tingkat stasiun, serta memberikan justifikasi pemilihan metrik dari perspektif ilmiah dan operasional.

$$MAPE^{(j)} = \frac{100\%}{N_j} \sum_{i=1}^{N_j} \left| \frac{y_i^{(j)} - \hat{y}_i^{(j)}}{y_i^{(j)}} \right| \quad (2)$$

MAPE menyajikan kesalahan absolut rata-rata sebagai persentase terhadap nilai aktual, sehingga mudah diinterpretasikan dan berguna untuk membandingkan performa lintas stasiun yang berskala berbeda. Akan tetapi, MAPE memiliki keterbatasan yaitu tidak terdefinisi bila terdapat $y_i^{(j)} = 0$ dan memberikan bobot berlebih pada kasus dengan $y_i^{(j)}$ kecil.

$$R^2^{(j)} = 1 - \frac{\sum_{i=1}^{N_j} (y_i^{(j)} - \hat{y}_i^{(j)})^2}{\sum_{i=1}^{N_j} (y_i^{(j)} - \bar{y}_i^{(j)})^2} \quad (3)$$

R^2 mengukur proporsi varians aktual yang dapat dijelaskan oleh model; berguna untuk menilai *explanatory power*. Nilai R^2 dapat negatif jika model lebih buruk daripada prediksi konstan $\bar{y}_i^{(j)}$. Akan tetapi, R^2 memiliki keterbatasan pada data berautokorelasi atau non-stasioner, R^2 dapat memberikan gambaran menyesatkan sehingga harus dikombinasikan dengan metrik kesalahan dan analisis residual.

$$MSE^{(j)} = \frac{1}{N} \sum_{i=1}^{N_j} (y_i^{(j)} - \hat{y}_i^{(j)})^2 \quad (4)$$

MSE menekankan kuadrat dari kesalahan sehingga sensitif terhadap outlier dengan mengembalikan nilai ke satuan asli target sehingga mempermudah interpretasi magnitudo kesalahan. Akan tetapi apabila distribusi kesalahan memiliki ekor berat, MSE dapat didominasi oleh beberapa kesalahan besar.

E. Prediksi dengan Model Terbaik

Pemilihan model akhir dilakukan berdasarkan evaluasi kuantitatif terhadap tiga metrik sebelumnya sehingga setiap dari 44 stasiun menggunakan model yang memenuhi kriteria performa terbaik pada level lokal. Model terpilih selanjutnya digunakan untuk menghasilkan prediksi akhir dengan menerapkan prosedur preprocessing yang identik dengan tahap pelatihan (penanganan *missing value*, transformasi/skalasi, *encoding*, dsb.) untuk menghindari kebocoran informasi, dan semua keluaran prediksi disimpan per-stasiun beserta metadata *reproducibility* (versi model, hiperparameter, *seed*, *timestamp*, dan skema pra- pemrosesan data)


III. HASIL DAN PEMBAHASAN

A. Hasil Ekstraksi Data Gambar Curah Hujan

Proses mengubah data curah hujan harian dari gambar grafik menjadi data digital berhasil dilakukan. Metode *Computer Vision* yang dipakai mampu mengambil data deret waktu dari gambar yang sebelumnya tidak bisa diolah oleh komputer.


Tantangan utama dalam proses ini ada dua. Pertama, ketersediaan rentang waktu data yang bervariasi antar stasiun. Secara keseluruhan, dataset yang digunakan mencakup periode dari tahun 1980 hingga 2024. Namun, tidak semua stasiun memiliki data yang lengkap sejak 1980, beberapa stasiun baru memiliki catatan data mulai tahun 2009, 2011, atau tahun-tahun lainnya. Tantangan kedua adalah titik awal data yang tidak seragam dalam grafik tahunan itu sendiri. Misalnya, untuk satu stasiun, data tahun 2010 bisa dimulai dari 1 Januari, namun data tahun 2012 baru dimulai pada 1 Mei. Untuk mengatasi ini, diperlukan penyesuaian dengan intervensi peneliti. Peneliti memeriksa dan menetapkan titik awal serta akhir dari sumbu-x (sumbu waktu) untuk setiap gambar grafik.

Proses penyelamatan data (*data rescue*) ini berhasil mendigitalisasi arsip-arsip grafik, terutama dari periode-periode awal yang datanya belum tersedia secara digital, dan menambahkan ribuan titik data harian baru ke dalam kumpulan data gabungan. Untuk memeriksa hasilnya, dilakukan perbandingan visual. gambar 1 menampilkan contoh salah satu grafik curah hujan historis dalam format gambar aslinya.



Gambar 1. Contoh Grafik Asli dari Gambar Curah Hujan Stasiun Admiralty Tahun 2009

Setelah melalui proses ekstraksi, data dari grafik tersebut berhasil diubah menjadi format deret waktu digital seperti yang ditunjukkan pada Gambar 2.



Gambar 2. Line chart Hasil Ekstraksi dari Gambar Curah Hujan Stasiun Admiralty Tahun 2009

Dengan membandingkan kedua gambar tersebut, terlihat jelas bahwa kurva data hasil digitalisasi (Gambar 2) mampu mereplikasi pola dan nilai pada grafik aslinya (Gambar 1) dengan sangat akurat. Hal ini membuktikan bahwa pendekatan yang digunakan telah berhasil.

B. Perbandingan Model Prediksi

Ketiga model yang diuji coba yaitu *Linear Regression*, *XGBoost*, dan *Gradient Boosting Regression* dibuat dan diuji menggunakan data dari 44 stasiun. Untuk menunjukkan perbandingannya, hasil penilaian dari empat contoh stasiun disajikan pada


TABEL 1. MATRIKS EVALUASI BEBERAPA STASIUN DI MSS

Linear Regression			
Stasiun	MAPE	MSE	R2
Paya Lebar	5.5122E+15	17.249	0.882
Ulu Pandan	5.6036E+15	19.764	0.934
Marine Parade	4.3662E+15	20.419	0.939
Jurong Island	1.8491E+16	25.116	0.743
XGBoost			
Stasiun	MAPE	MSE	R2
Paya Lebar	6.0140E+15	13.014	0.787
Ulu Pandan	1.3355E+14	18.824	0.937
Marine Parade	2.5880E+14	21.887	0.913
Jurong Island	3.3272E+13	22.882	0.922
Gradient Boosting Regression			
Stasiun	MAPE	MSE	R2
Paya Lebar	1.4208E+15	8.167	0.897
Ulu Pandan	3.8445E+14	10.570	0.965
Marine Parade	2.3251E+14	12.317	0.937
Jurong Island	3.4673E+15	12.927	0.925

Hasil pada Tabel 1. menunjukkan pola yang jelas bahwa model *Gradient Boosting Regression* jauh lebih baik dari dua model lainnya. Di semua contoh stasiun, *Gradient Boosting Regression* selalu menghasilkan nilai MSE yang paling rendah, yang berarti tingkat kesalahan prediksinya lebih kecil. Selain itu, nilai R^2 yang tinggi (mencapai 0.965 di Ulu Pandan) menunjukkan kemampuannya yang sangat baik untuk menjelaskan perubahan data curah hujan.


C. Penentuan Model Terbaik dan Analisis Hasil

Hasil yang disajikan untuk beberapa stasiun perwakilan pada Tabel 1. menegaskan temuan yang lebih luas, di mana keunggulan model *Gradient Boosting Regression* terbukti berlaku secara merata untuk keseluruhan 44 stasiun. Model ini secara konsisten memberikan nilai MSE terendah dan R^2 tertinggi di setiap lokasi. Karena hasilnya sangat seragam, maka *Gradient Boosting Regression* dipilih sebagai model utama untuk semua stasiun. Untuk memberikan bukti visual atas kinerja model terbaik ini, disajikan perbandingan antara data curah hujan aktual dengan hasil prediksi dari model *Gradient Boosting Regression* pada dua stasiun perwakilan.



Gambar 3. Perbandingan Hasil Prediksi Model vs Data Aktual (Stasiun Paya Lebar)

Gambar 3 menunjukkan perbandingan hasil prediksi pada Stasiun Paya Lebar. Selanjutnya, untuk menunjukkan bahwa kinerja unggul ini tidak terbatas pada satu lokasi, Gambar 4. menampilkan perbandingan serupa untuk Stasiun Marine Parade.



Gambar 4. Perbandingan Hasil Prediksi Model vs Data Aktual (Stasiun Marine Parade)

Dari kedua grafik di atas, terlihat jelas bahwa garis prediksi mampu mengikuti pola dan puncak dari garis data aktual dengan cukup akurat. Kemampuan model untuk menangkap fluktuasi secara konsisten di dua stasiun yang berbeda ini mengonfirmasi secara visual mengapa model *Gradient Boosting Regression* unggul berdasarkan metrik kuantitatif.

D. Interpretasi Hasil

Keunggulan kinerja model *Gradient Boosting Regression* dapat dijelaskan oleh kemampuannya menangkap hubungan non-linear yang kompleks dalam data cuaca. Berbeda dengan *Linear Regression*, model *ensemble* seperti *Gradient Boosting* dirancang untuk memodelkan interaksi rumit antara berbagai variabel seperti suhu, kelembapan, dan angin. Cara kerja

Gradient Boosting yang membangun modelnya secara bertahap, di mana setiap langkahnya fokus memperbaiki kesalahan dari langkah sebelumnya, terbukti sangat efektif untuk data cuaca yang rumit dan beragam.

E. Manfaat Penelitian dan Penerapannya

Penelitian ini memiliki dua manfaat penting. Pertama, penelitian ini membuktikan bahwa proses penyelamatan data (*data rescue*) menggunakan *computer vision* ini berguna dan layak dilakukan. Arsip data lama yang sangat besar kini bisa digabungkan ke dalam proses pembuatan model saat ini. Ini membuktikan bahwa data lama tersebut adalah sumber informasi penting yang berhasil dimanfaatkan.

Kedua, cara kerja ini sangat berguna untuk Singapura dan Indonesia. Untuk dinas cuaca Singapura, model tunggal yang kuat ini bisa menjadi dasar sistem peringatan dini banjir yang lebih baik. Bagi Indonesia, melalui BMKG, penelitian ini menawarkan panduan untuk melakukan hal yang sama pada arsip data cuaca historis.

F. Kekurangan dan Saran untuk Penelitian Selanjutnya

Penelitian ini memiliki beberapa kekurangan yang perlu diakui. Pertama, proses pengambilan data dari gambar memerlukan intervensi peneliti untuk kalibrasi sumbu waktu, yang bisa memakan waktu. Kedua, cara mengisi data yang hilang mungkin tidak bisa menangkap semua kejadian cuaca ekstrem. Ketiga, penelitian ini hanya membandingkan tiga jenis model. Untuk penelitian selanjutnya, beberapa hal bisa dieksplorasi. Misalnya, mengembangkan metode deteksi sumbu otomatis untuk mengurangi kebutuhan intervensi peneliti.

IV. KESIMPULAN

Penelitian ini dilaksanakan untuk menjawab tantangan dalam meningkatkan akurasi prediksi curah hujan di lingkungan perkotaan tropis dengan mengintegrasikan data meteorologi standar dengan data historis yang belum dimanfaatkan dari arsip grafik. Melalui penerapan metode *computer vision* untuk penyelamatan data (*data rescue*) dan pemodelan *machine learning*, penelitian ini berhasil mengembangkan dan memvalidasi sebuah kerangka kerja yang efektif. Berdasarkan hasil dan pembahasan yang telah diuraikan, dapat ditarik beberapa kesimpulan utama:

1) Proses penyelamatan data (*data rescue*) dari arsip grafik terbukti sangat efektif. Meskipun dihadapkan pada tantangan seperti variasi rentang waktu data dan kebutuhan intervensi peneliti untuk kalibrasi, metode yang digunakan berhasil mendigitalisasi data historis dengan akurasi tinggi. Hal ini membuktikan bahwa arsip visual merupakan sumber daya berharga yang dapat diubah menjadi aset data yang dapat diolah untuk pemodelan prediktif.

2) Model *Gradient Boosting Regression* secara konsisten menjadi model dengan kinerja terbaik. Dari ketiga model yang diuji, *Model Gradient Boosting Regression* secara seragam menunjukkan superioritas di seluruh 44 stasiun pengamatan dengan nilai MSE terendah dan R^2 tertinggi. Temuan ini menegaskan bahwa model *ensemble* non-linear sangat cocok untuk menangkap hubungan yang kompleks dan dinamis dalam data cuaca.

3) Kerangka kerja yang diusulkan memiliki potensi penerapan praktis yang signifikan. Kemampuan model terbaik untuk mengikuti pola data aktual, termasuk pada puncak-puncak curah hujan, menunjukkan bahwa metode ini dapat diandalkan untuk menghasilkan prediksi yang lebih akurat. Hal ini berimplikasi langsung pada peningkatan sistem peringatan dini banjir di perkotaan.

Secara keseluruhan, kontribusi utama dari penelitian ini adalah penyediaan sebuah alur kerja yang terbukti berhasil, mulai dari ekstraksi data yang sebelumnya tidak dapat diakses hingga menghasilkan model prediksi yang kuat. Kerangka kerja ini tidak hanya relevan bagi Singapura, tetapi juga menawarkan panduan yang jelas bagi lembaga seperti BMKG di Indonesia untuk memodernisasi arsip data mereka dan meningkatkan ketahanan terhadap bencana hidrometeorologi.

REFERENSI

- [1] IPCC, *Climate Change 2021: The Physical Science Basis*, Cambridge University Press, 2021.
- [2] Trenberth, K. E., "Changes in precipitation with climate change," *Climate Research*, vol. 47, no. 1–2, pp. 123–138, 2011.
- [3] Chow, W. T. L., et al., "Urban heat island research in Singapore," *Singapore Journal of Tropical Geography*, vol. 35, no. 1, pp. 3–17, 2014.
- [4] Rahmat, R., "Flash flood events in Singapore: Past and future," *Meteorological Service Singapore Technical Report*, 2020.
- [5] Meteorological Service Singapore, "Climate data and monitoring," [Daring]. Tersedia: <https://www.weather.gov.sg>
- [6] Lee, T. C., et al., "Mesoscale convective systems in Southeast Asia," *Quarterly Journal of the Royal Meteorological Society*, vol. 144, no. 713, pp. 1404–1420, 2018.
- [7] Tangang, F., et al., "Projected changes in rainfall in Southeast Asia based on CORDEX-SEA simulations," *Climate Dynamics*, vol. 52, no. 1–2, pp. 231–245, 2019.
- [8] WMO, *Guidelines on Climate Data Rescue*, World Meteorological Organization, 2016.
- [9] He, K., et al., "Image-based time series data extraction for climate analysis," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 59, no. 7, pp. 5965–5976, 2021.
- [10] BMKG, "Data iklim historis Indonesia," [Daring]. Tersedia: <https://www.bmkg.go.id>
- [11] Siswanto, S., et al., "Development of high-resolution climate data for Indonesia," *International Journal of Climatology*, vol. 37, no. 10, pp. 4305–4320, 2017.
- [12] Aldrian, E., dan Dwi Susanto, R., "Identification of three dominant rainfall regions within Indonesia and their relationship to sea surface temperature," *International Journal of Climatology*, vol. 23, pp. 1435–1452, 2003.